

SARRA BEN DOUB

Data Scientist & AI Engineer · LLMs · RAG · Document AI · Machine Learning

+216 26 236 449 · sarrabendoub5@gmail.com · Tunis, Tunisie · linkedin.com/in/sarra-ben-doub · github.com/SarraBendoub · sarrabendoub.github.io

PROFIL

Ingénieure diplômée de l'ENSIT en mathématiques appliquées et modélisation, avec une expérience en Data Science et AI Engineering dans des environnements financiers et assurantiers. Je développe des solutions de Machine Learning, d'IA générative et de traitement intelligent des documents appliquées aux données financières, au risque et à l'analyse. Je recherche une opportunité en Data Science, AI Engineering ou Machine Learning dans le secteur financier en Tunisie : banque, assurance, leasing et fintech, ou chez les cabinets et éditeurs qui les accompagnent.

EXPÉRIENCES PROFESSIONNELLES

BIAT — Traitement intelligent des documents financiers & risque de crédit

Févr. – Juil. 2026

Banque Internationale Arabe de Tunisie · AI Engineer & Data Scientist — Projet de fin d'études

- Validation & extraction documentaire.** Contrôle de la nature du document, puis extraction des tableaux financiers depuis les états déposés en PDF auprès du CMF avec Docling et l'OCR (bilan, compte de résultat, flux de trésorerie), structurés et stockés dans MongoDB.
- Data cleaning & verification.** Nettoyage, normalisation et contrôle des données extraites (erreurs d'OCR, valeurs incohérentes), puis affectation au plan comptable.
- Analyse financière & crédit.** Application Streamlit d'aide à la décision : ratios de liquidité, solvabilité, rentabilité et endettement, comparaison N / N-1.
- Synthèse générée par LLM** avec niveaux d'appréciation (favorable, réservé, défavorable, à approfondir), la décision finale restant à l'analyste. Pipeline orchestré n8n, conteneurisé Docker.

Tech : Python · Docling / OCR · MongoDB · Streamlit · LLM · n8n · Docker

GAT Assurances — Gestion des sinistres & NLP

Juin – Août 2025

Assurance · IA & développement full-stack · Stage

- Plateforme de gestion des sinistres** : site public, espace client et back-office, conçue avec un graphiste pour l'identité visuelle et l'expérience utilisateur.
- Classification d'intention** par moteur de règles en français (accents manquants, fautes de frappe), relayé par une classification zero-shot BART-large-MNLI quand aucune règle ne tranche.
- Assistant conversationnel** collectant les informations manquantes et créant la déclaration (catégorie, priorité, numéro de suivi) transmise au back-office.

Tech : Python · Flask · Transformers · BART-large-MNLI · NLP · SQLite · HTML/CSS/JS | github.com/SarraBendoub/insurance-agency-platform

VALUE — Data Engineering & analyse de données

Juil. 2024

Data Science · Data Engineering · Stage

- Collecte multi-sources** automatisée (Scrapy, Selenium), puis nettoyage, structuration et fusion des données en un jeu exploitable.
- Segmentation K-Means** et cartographie interactive Folium pour visualiser la répartition des sites et identifier les zones à faible visibilité numérique.

Tech : Python · Scrapy · Selenium · Pandas · scikit-learn · K-Means · Folium | github.com/SarraBendoub/HeritageScope

BNA — Chatbot de service client

Avr. – Mai 2023

Banque · NLP & Machine Learning · Stage

- Classification d'intention** sur requêtes en français : prétraitement linguistique, entraînement et comparaison de deux architectures, FNN et LSTM.
- Réponses automatisées** depuis la base FAQ de la banque (services bancaires, BNA eBanking, Mandat Cash), déployées via Flask.

Tech : TensorFlow · Keras · NLTK · Python · Flask | github.com/SarraBendoub/-chatbot_BNA-main

PROJETS PERSONNELS — IA FINANCIÈRE & RISQUE

CreditGuard — Scoring de crédit explicable et surveillé

2026

Risque de crédit · Probabilité de défaut

- Modèle **LightGBM** de probabilité de défaut, **AUC 0,757**, avec explicabilité **SHAP** par prédiction.
- Surveillance de dérive par **PSI**, Kolmogorov-Smirnov et **Chi-2** pour détecter les changements de distribution. Dashboard Streamlit, packaging Docker.

Tech : Python · LightGBM · SHAP · SciPy · Streamlit · Docker | github.com/SarraBendoub/CreditGuard

FraudGuard — Détection de fraude & surveillance LCB-FT

2026

Fraude · Criminalité financière · Surveillance des transactions

- Détection de fraude **XGBoost** sur **6,4 M de transactions** à **0,13 % de fraude** : **PR-AUC 0,89**, **F1 0,82**, seuil ajusté sur le compromis entre fraudes manquées et fausses alertes.
- Moteur de règles de transaction monitoring (vélocité, structuration, schémas de comptes), niveaux d'action **BLOCK / REVIEW / ALLOW**, explicabilité **SHAP** des alertes.
- Data leakage détectée et corrigée** : une première version atteignait 0,9998 de PR-AUC via des variables postérieures à la transaction, écartées depuis.

Tech : Python · XGBoost · SHAP · pandas · Streamlit | github.com/SarraBendoub/FraudGuard

COMPÉTENCES TECHNIQUES

Données financières & Risque

Risque de crédit · Probabilité de défaut · États financiers · Détection de fraude · Model Monitoring · Explainable AI

Machine Learning

Python · Scikit-learn · XGBoost · LightGBM · SHAP · PyTorch · TensorFlow · Statistiques

Data

SQL · PostgreSQL · MongoDB · Pandas · NumPy · Web scraping (Scrapy, Selenium, BeautifulSoup)

Document AI

OCR · Docling · Traitement documentaire · LLM

IA générative

RAG · Transformers · LLM · Ollama · Groq

Déploiement

Docker · FastAPI · Streamlit · n8n · Git

Restitution & Data Viz

Power BI · Matplotlib · Seaborn · Dashboards Streamlit

FORMATION

Diplôme d'ingénieur — Math. appliquées & modélisation, ENSIT

2023 – 2026

Licence — Data Science, FST

2020 – 2023

Baccalauréat — Sciences expérimentales

2020

CERTIFICATION & LANGUES

Microsoft Azure AI Fundamentals (AI-900)

Arabe maternelle · Français courant · Anglais (TOEIC) · Italien A1