

SARRA BEN DOUB

AI Engineer · Data Scientist · Generative AI · Document Intelligence · Machine Learning

+216 26 236 449 · sarrabendoub5@gmail.com · Tunis, Tunisie · linkedin.com/in/sarra-ben-doub · github.com/SarraBendoub · sarrabendoub.github.io/ai

PROFIL

Ingénieure diplômée de l'École Nationale Supérieure d'Ingénieurs de Tunis (ENSIT) en mathématiques appliquées et modélisation (2026), spécialisée en Data Science et IA, après une licence en Data Science à la Faculté des Sciences de Tunis (FST). Je construis des applications de Machine Learning et de LLM, des données brutes jusqu'à l'outil utilisé au quotidien : traitement intelligent des documents (IDP), RAG et sorties structurées validées avant usage. Ouverte aux opportunités.

EXPÉRIENCES PROFESSIONNELLES

BIAT — Traitement intelligent des documents financiers & risque de crédit Févr. – Juil. 2026

Banque Internationale Arabe de Tunisie · AI Engineer & Data Scientist — Projet de fin d'études

- **Validation & extraction documentaire.** Contrôle de la nature du document, puis extraction des tableaux financiers depuis les états déposés en PDF auprès du CMF avec Docling et l'OCR (bilan, compte de résultat, flux de trésorerie), structurés et stockés dans MongoDB.
- **Data cleaning & verification.** Nettoyage, normalisation et contrôle des données extraites (erreurs d'OCR, valeurs incohérentes), puis affectation au plan comptable.
- **Analyse et synthèse générée par LLM.** Application Streamlit (ratios de liquidité, solvabilité, rentabilité, endettement) puis synthèse rédigée avec niveaux d'appréciation, la décision restant à l'analyste. Pipeline orchestré n8n, conteneurisé Docker.

Tech : Python · Docling / OCR · MongoDB · Streamlit · LLM · n8n · Docker

GAT Assurances — Gestion des sinistres & NLP

Juin – Août 2025

Assurance · IA & développement full-stack · Stage

- **Plateforme de gestion des sinistres** : site public, espace client et back-office, conçue avec un graphiste pour l'identité visuelle et l'expérience utilisateur.
- **Classification d'intention** par moteur de règles en français (accents manquants, fautes de frappe), relayé par une classification zero-shot BART-large-MNLI quand aucune règle ne tranche.

Tech : Python · Flask · Transformers · BART-large-MNLI · NLP · SQLite · HTML/CSS/JS | github.com/SarraBendoub/insurance-agency-platform

VALUE — Data Engineering & analyse de données

Juil. 2024

Data Science · Data Engineering · Stage

- **Collecte multi-sources** automatisée (Scrapy, Selenium), nettoyage et fusion des données, puis **segmentation K-Means** de 314 sites et cartographie Folium.

Tech : Python · Scrapy · Selenium · Pandas · scikit-learn · K-Means · Folium | github.com/SarraBendoub/HeritageScope

BNA — Chatbot de service client

Avr. – Mai 2023

Banque · NLP & Machine Learning · Stage

- **Classification d'intention** sur requêtes en français : prétraitement NLTK, entraînement et comparaison de deux architectures, FNN et LSTM, déploiement Flask.

Tech : TensorFlow · Keras · NLTK · Python · Flask | github.com/SarraBendoub/-chatbot_BNA-main

PROJETS PERSONNELS — IA & MACHINE LEARNING

CreditDoc-AI — Extraction sur documents scannés & questions-réponses

2026

Document AI · OCR · LLM · RAG

- Prétraitement image, OCR et reconstruction des tableaux d'un état financier scanné, puis extraction en **JSON validé par Pydantic** : règles de libellés d'abord, LLM local pour les champs manquants, provenance conservée.
- **RAG ancré** sur le document : réponse rédigée depuis les seuls passages retrouvés, citation de la page, refus explicite quand l'information est absente.

Tech : Python · OpenCV · OCR · Ollama · Pydantic · Streamlit

News-Radar — Recherche sémantique & chatbot RAG

2026

RAG · pgvector · Embeddings locaux · FastAPI

- Ingestion RSS planifiée et idempotente (~1 000 articles), embeddings calculés en local et stockés dans **PostgreSQL / pgvector** ; chatbot **RAG** ancré sur le corpus, API **FastAPI**.

Tech : Python · FastAPI · PostgreSQL / pgvector · fastembed · Ollama · Docker

CreditGuard — Scoring de crédit explicable et surveillé

2026

Risque de crédit · Probabilité de défaut

- Modèle **LightGBM** de probabilité de défaut, **AUC 0,757**, explicabilité **SHAP** par prédiction et surveillance de dérive (PSI, Kolmogorov-Smirnov, Chi-2). Dashboard Streamlit, packaging Docker.

Tech : Python · LightGBM · SHAP · SciPy · Streamlit · Docker | github.com/SarraBendoub/CreditGuard

FraudGuard — Détection de fraude & surveillance LCB-FT

2026

Fraude · Criminalité financière · Surveillance des transactions

- Détection de fraude **XGBoost** sur **6,4 M de transactions à 0,13 % de fraude** : **PR-AUC 0,89, F1 0,82**, seuil ajusté sur le compromis entre fraudes manquées et fausses alertes.
- Moteur de règles de transaction monitoring (vélocité, structuration), niveaux d'action **BLOCK / REVIEW / ALLOW**, explicabilité **SHAP** des alertes, et une **fuite de données détectée puis corrigée** (0,9998 de PR-AUC obtenus via des variables postérieures à la transaction).

Tech : Python · XGBoost · SHAP · pandas · Streamlit | github.com/SarraBendoub/FraudGuard

COMPÉTENCES TECHNIQUES

Data Science & AI Engineering

Risque de crédit · Probabilité de défaut · États financiers · Détection de fraude · Model Monitoring · Explainable AI

Machine Learning

Python · Scikit-learn · XGBoost · LightGBM · SHAP · PyTorch · TensorFlow · Statistiques

Data

SQL · PostgreSQL · MongoDB · Pandas · NumPy · Web scraping (Scrapy, Selenium, BeautifulSoup)

Document AI

OCR · Docling · Traitement documentaire · LLM

IA générative

RAG · Transformers · LLM · Ollama · Groq

Déploiement

Docker · FastAPI · Streamlit · n8n · Git

FORMATION

Diplôme d'ingénieur — Math. appliquées & modélisation, École Nationale Supérieure d'Ingénieurs de Tunis

2023 – 2026

Licence — Data Science, Faculté des Sciences de Tunis

2020 – 2023

Baccalauréat — Sciences expérimentales

2020

CERTIFICATION & LANGUES

Microsoft Azure AI Fundamentals (AI-900)

Arabe maternelle · Français courant · Anglais (TOEIC) · Italien A1